最近在刷cs231n的课程和作业，在这里分享下自己的学习过程，同时也希望能够得到大家的指点。

写在前面：

1. 这仅仅是自己的学习笔记，如果侵权，还请告知;
2. 代码是参照lightaime的github，在其基础之上做了一些修改;
3. 在我之前，已有前辈在他的知乎上分享过类似内容;
4. 讲义是参照杜客等人对cs231n的中文翻译。

温馨提醒：

1. 这篇文档是建立在你已经知道神经网络的基本原理，如果在阅读本篇文档过程中有些原理不是很清楚，请移步温习下相关知识（参阅cs231n讲义）;
2. 文档的所有程序是使用python3.5实现的，如果你是python2的用户，可能要对代码稍作修改；
3. 文章频繁提到将代码保存到`.py`中，是为了方便接下来的模块导入，希望读者可以理解。

使用神经网络完成cifa10的分类工作，主要有以下几个内容：

1. 神经网络模型构建；
2. 数据处理；
3. 训练；
4. 预测。

1 两层神经网络模型的构建

1.1 损失函数和梯度

我们先来看下每一层神经网络的表达式
第一层神经网络表达式，这里激活函数采用的是Relu：

$$z_1 = w_1 x + b_1$$

$$h = \max(0, z_1)$$

第二层神经网络表达式：

$$z_2 = w_2 h + b_2$$

$$f(z_2)$$

其中第二层采用softmax作为激活函数。
根据上式我们可以计算出每一层的输出。

梯度计算是利用方向传播算法计算的，也就是说，第一层的梯度是在第二层梯度的基础之上计算出来的，这里我们可以放一张cs231n中的ppt。

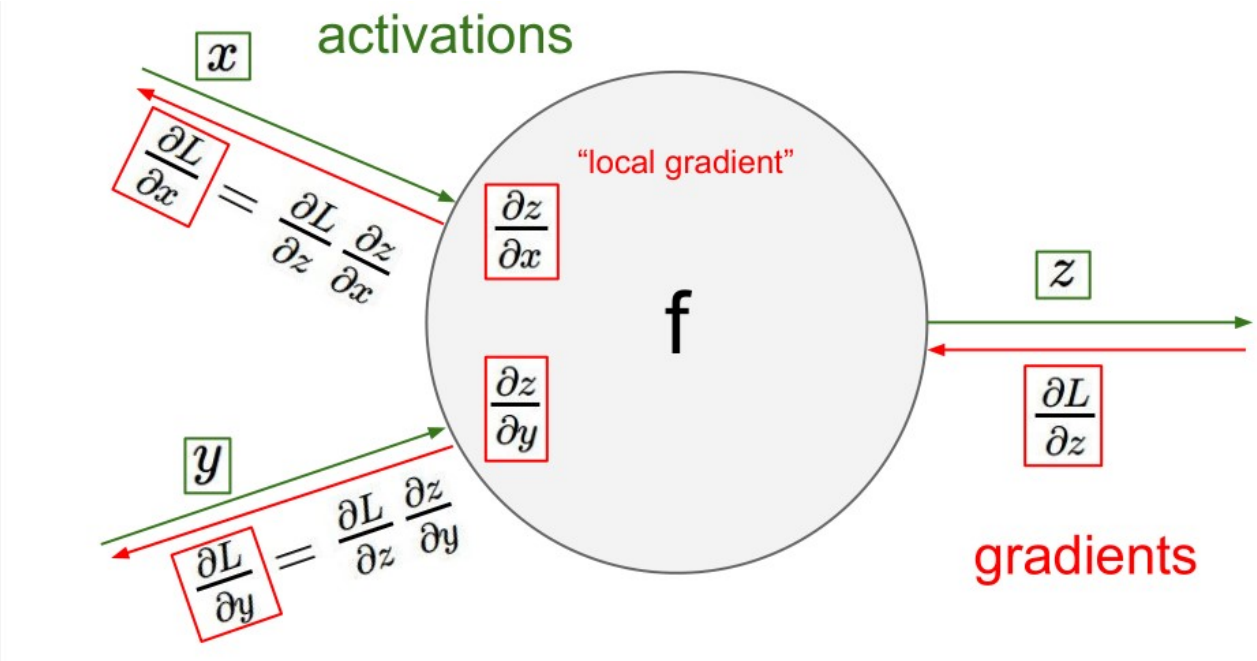

绿色表示的loss值，红色表示的是梯度值。

代码如下：

```
def __init__(self,input_size,hidden_size,output_size,std=1e-4):
    self.params={}
    self.params['W1']=std*np.random.randn(input_size,hidden_size)
    self.params['b1']=np.zeros(hidden_size)
    self.params['W2']=std*np.random.randn(hidden_size,output_size)
    self.params['b2']=np.zeros(output_size)


def loss(self,X,y=None,reg=0.0):

    W1,b1=self.params['W1'],self.params['b1']
    W2,b2=self.params['W2'],self.params['b2']
    N,D=X.shape

    scores=None

```

```
    h_output=np.maximum(0,X.dot(W1)+b1) #第一层输出(N,H)，Relu激活函数
    scores=h_output.dot(W2)+b2 #第二层激活函数前的输出(N,C)

    if y is None:
        return scores
    loss=None

    shift_scores=scores-np.max(scores,axis=1).reshape((-1,1))

 softmax_output=np.exp(shift_scores)/np.sum(np.exp(shift_scores),axis=1).
reshape(-1,1)
    loss=-np.sum(np.log(softmax_output[range(N),list(y)]))
    loss/=N
    loss+=0.5*reg*(np.sum(W1*W1)+np.sum(W2*W2))#正则项

    grads={}


    #第二层梯度计算
    dscores=softmax_output.copy()
    dscores[range(N),list(y)]-=1
    dscores/=N
    grads['W2']=h_output.T.dot(dscores)+reg*W2
    grads['b2']=np.sum(dscores,axis=0)

    #第一层梯度计算
    dh = dscores.dot(W2.T)
    dh_ReLu = (h_output > 0) * dh
    grads['W1'] = X.T.dot(dh_ReLu) + reg * W1
    grads['b1'] = np.sum(dh_ReLu, axis=0)

    return loss,grads
```

这里，我们说下对输入数据的要求 `X` (N,D)维输入数据, `y` (N,)标签, `W1` (D,H)第一层权重, `b1` (H,)第一层偏置, `W2` (H,C)第二层权重, `b2` (C,)第二层偏置
上面的代码重点是反向传播阶段，输入是图像数据时，我们都是对矩阵和向量进行操作，然而，在操作的时候，要注意关注维度和转置操作。这里我们引用下cs231n中讲义的解释：

> **提示：要分析维度！注意不需要去记忆dW和dX的表达，因为它们很容易通过维度推导出来。例如，权重的梯度dW的尺寸肯定和权重矩阵W的尺寸是一样的，而这又是由X和dD的矩阵乘法决定的（在上面的例子中X和W都是数字不是矩阵）。总有一个方式是能够让维度之间能够对的上的。例如，X的尺寸是[10x3]，dD的尺寸是[5x3]，如果你想要dW和W的尺寸是[5x10]，那就要dD.dot(X.T)。**

1.2 训练和预测模型

接下来是训练和预测模型。
我们依旧使用SGD进行训练，并将训练过程中的每一轮的平均损失函数、平均训练准确率、平均验证准确率保存
在`loss_history`，`train_acc_history`，`val_acc_history`中。实现的代码如下：

```
def train(self,X,y,X_val,y_val,learning_rate=1e-3,learning_rate_decay=0.95,reg=1e-5,num_iters=100,
          batch_size=200,verbose=False):
    num_train=X.shape[0]
    iterations_per_epoch=max(num_train/ batch_size,1) #每一轮迭代数目
    loss_history=[]
    train_acc_history=[]
    val_acc_history=[]

    for it in range(num_iters):
        X_batch=None
        y_batch=None

        idx=np.random.choice(num_train,batch_size,replace=True)
        X_batch=X[idx]
        y_batch=y[idx]
        loss,grads=self.loss(X_batch,y=y_batch,reg=reg)
        loss_history.append(loss)

        #参数更新
        self.params['W2']+=-learning_rate*grads['W2']
        self.params['b2']+=-learning_rate*grads['b2']
        self.params['W1']+=-learning_rate*grads['W1']
        self.params['b1']+=-learning_rate*grads['b1']

        if verbose and it % 100 ==0: #每迭代100次，打印
            print('iteration %d / %d : loss %f' % (it,num_iters,loss))

        if it % iterations_per_epoch==0:  #一轮迭代结束
            train_acc=(self.predict(X_batch)==y_batch).mean()
            val_acc=(self.predict(X_val)==y_val).mean()
            train_acc_history.append(train_acc)
            val_acc_history.append(val_acc)
    #更新学习率
            learning_rate*=learning_rate_decay

```

```
    return {
        'loss_history':loss_history,
        'train_acc_history':train_acc_history,
        'val_acc_history':val_acc_history
    }
```

之后，我们只需要使用训练保存好的参数，就可以完成预测，代码如下：

```
def predict(self,X):
    y_pred=None
    h=np.maximum(0,X.dot(self.params['W1'])+self.params['b1'])
    scores=h.dot(self.params['W2'])+self.params['b2']
    y_pred=np.argmax(scores,axis=1)
    return y_pred
```

以上所有代码我们保存在`neural_net.py`文件中。
这样，我们就完成了两层神经网络模型的构建工作。

2 数据处理

数据处理部分，同前面我们所叙述的，先将cifar10图片转成数组，然后对其进行归一化处理（减去均值）。因为前面已经叙述很多，我们这里就不再赘述，只是将代码给大家贴出来：

```
def get_cifar_data(num_training=49000,num_validation=1000,num_test=1000):
    cifar10_dir='..\knn\cifar-10-batches-py'
    X_train,y_train,X_test,y_test=load_cifar10(cifar10_dir)
    # 验证集
    mask=range(num_training,num_training+num_validation)
    X_val=X_train[mask]
    y_val=y_train[mask]
    #训练集
    mask=range(num_training)
    X_train=X_train[mask]
    y_train=y_train[mask]
    #测试集
    mask=range(num_test)
    X_test=X_test[mask]
    y_test=y_test[mask]

    mean_image=np.mean(X_train,axis=0)
    X_train-=mean_image
```

```
    X_val-=mean_image
    X_test-=mean_image

    X_train=X_train.reshape(num_training,-1)
    X_val=X_val.reshape(num_validation,-1)
    X_test=X_test.reshape(num_test,-1)

    return X_train,y_train,X_val,y_val,X_test,y_test
```

得到结果如下：

```
train data shape: (49000, 3072)
train labels shape: (49000,)
validation data shape: (1000, 3072)
validation labels shape: (1000,)
test data shape: (1000, 3072)
test labels shape: (1000,)
```

3 模型训练

3.1 网络初始训练

我们使用带有动量的SGD来训练我们的网络，也就是说，我们在每一轮结束之后更新我们的学习速率，这里我们是乘上一个衰减率。
代码如下：

```
input_size=32*32*3
hidden_size=50
num_classes=10
net=TwoLayerNet(input_size,hidden_size,num_classes)
stats=net.train(X_train,y_train,X_val,y_val,num_iters=1000,batch_size=200
,learning_rate=1e-4,learning_rate_decay=0.95,
                reg=0.5,verbose=True)
val_acc=(net.predict(X_val)==y_val).mean()
print('valiadation accuracy:',val_acc)
```

输出结果如下：

```
iteration 0 / 1000 : loss 2.302975
iteration 100 / 1000 : loss 2.302409
```

```
iteration 200 / 1000 : loss 2.297453
iteration 300 / 1000 : loss 2.274700
iteration 400 / 1000 : loss 2.211710
iteration 500 / 1000 : loss 2.126385
iteration 600 / 1000 : loss 2.074668
iteration 700 / 1000 : loss 2.056960
iteration 800 / 1000 : loss 2.002378
iteration 900 / 1000 : loss 2.004737
valiadation accuracy: 0.279
```

0.28的准确率其实并不是很好，我们需要知道中间发生了什么，让我们的结果变得不理想，这里有两种方法：

1. 可视化loss和accuracy；
2. 可视化权重。
   我们来分别实现下。

3.1.1 loss和accura可视化

代码如下：

```
plt.subplot(211)
plt.plot(stats['loss_history'])
plt.title('loss history')
plt.xlabel('iteration')
plt.ylabel('loss')

plt.subplot(212)
plt.plot(stats['train_acc_history'],label='train')
plt.plot(stats['val_acc_history'],label='val')
plt.title('classification accuracy history')
plt.xlabel('epoch')
plt.ylabel('classification accuracy')
plt.show()
```

结果如下：

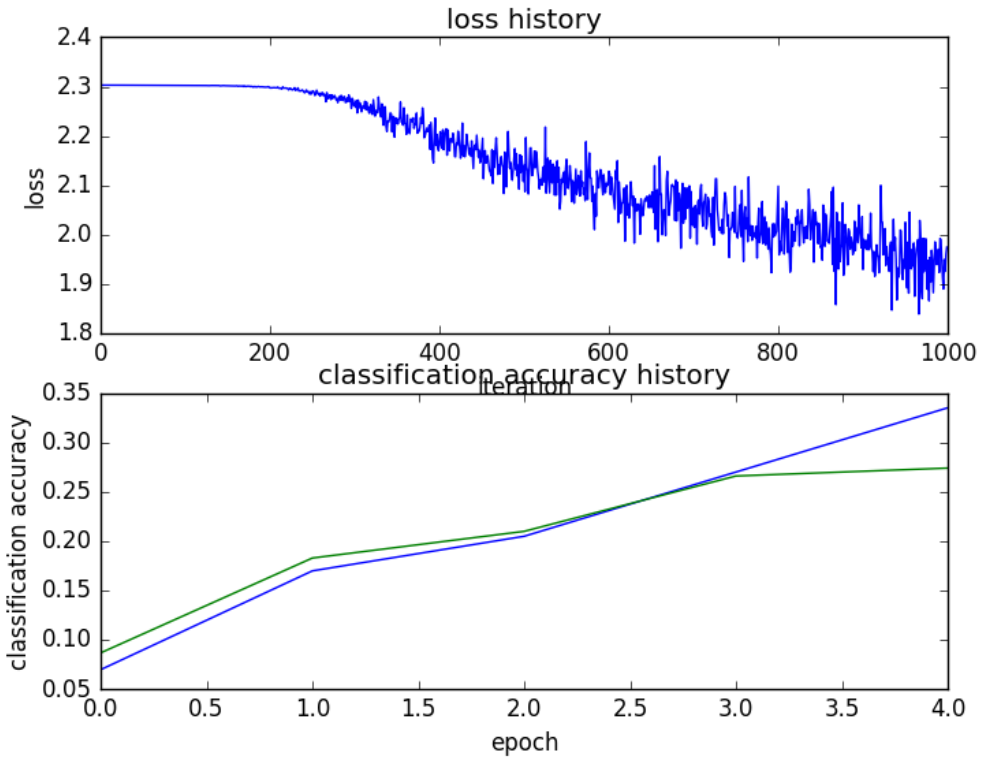

3.1.2 权重可视化

cs231n为我们提供好了可以权重可视化的函数，我们直接调用就好，不过我们还是看下看下这份代码：

```
def visualize_grid(Xs,ubound=255.0,padding=1):
    (N,H,W,C)=Xs.shape
    grid_size=int(ceil(sqrt(N)))
    grid_height=H*grid_size+padding*(grid_size-1)
    grid_width=W*grid_size+padding*(grid_size-1)
    grid=np.zeros((grid_height,grid_width,C))
    next_idx=0
    y0,y1=0,H
    for y in range(grid_size):
        x0,x1=0,W
        for x in range(grid_size):
            if next_idx<N:
                img=Xs[next_idx]
                low,high=np.min(img),np.max(img)
                grid[y0:y1,x0:x1]=ubound*(img-low)/(high-low)
                next_idx+=1
            x0+=W+padding
            x1+=W+padding
        y0+=H+padding
        y1+=H+padding
```

```
    return grid
```

这份代码要求我们输入的 `Xs` 是四维的。
我将这份代码保存在了 `vis_utils.py` 中。
我们调用它，来可视化下权重：

```
def show_net_weights(net):
    W1=net.params['W1']
    W1=W1.reshape(32,32,3,-1).transpose(3,0,1,2)
    plt.imshow(visualize_grid(W1,padding=3).astype('uint8'))
    plt.axis('off')
    plt.show()

show_net_weights(net)
```

可视化结果如下：

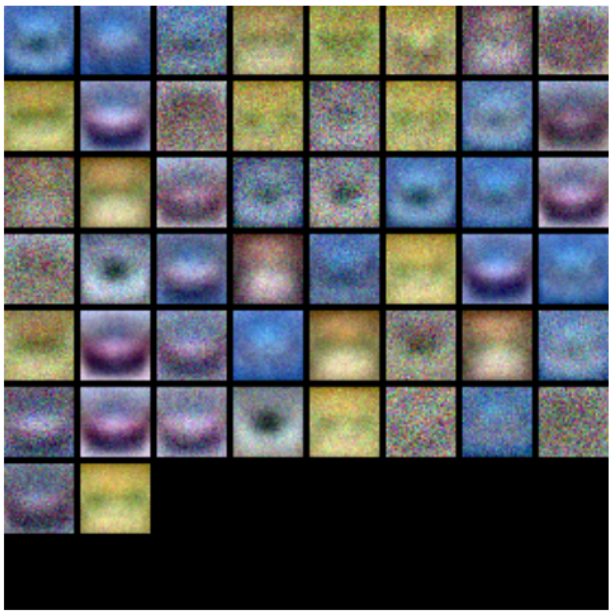

3.2 超参数调整

在调整超参数之前，我们先来分析下我们上面得到的可视化结果。
我们的loss曲线大致呈线性下降，这表明我们设置的学习率可能太低；训练集和验证集的准确率很接近，表明我们的模型复杂度不够，也就是欠拟合。（当然增加模型复杂度的话可能会导致过拟合。）
下面我们就通过交叉验证的方法来不断调整超参数。
代码如下：

```
input_size=input_size=32*32*3
num_classes=10
hidden_size=[75,100,125]
results={}
best_val_acc=0
best_net=None

learning_rates=np.array([0.7,0.8,0.9,1.0,1.1])*1e-3
regularization_strengths=[0.75,1.0,1.25]
print('running')
for hs in hidden_size:
    for lr in learning_rates:
        for reg in regularization_strengths:
            net=TwoLayerNet(input_size,hs,num_classes)


 stats=net.train(X_train,y_train,X_val,y_val,num_iters=1500,batch_size=200,
                            learning_rate=lr,learning_rate_decay=0.95,
                            reg=reg,verbose=False)
            val_acc=(net.predict(X_val)==y_val).mean()
            if val_acc >best_val_acc:
                best_val_acc=val_acc
                best_net=net
            results[(hs,lr,reg)]=val_acc

print('finshed')

for hs,lr,reg in sorted(results):
    val_acc=results[(hs,lr,reg)]
    print('hs %d lr %e reg %e val accuracy: %f' % (hs,lr,reg,val_acc))

print('best validation accuracy achieved during cross_validation: %f' % best_val_acc)
```

输出结果如下：

```
hs 75 lr 7.000000e-04 reg 7.500000e-01 val accuracy: 0.489000
hs 75 lr 7.000000e-04 reg 1.000000e+00 val accuracy: 0.475000
hs 75 lr 7.000000e-04 reg 1.250000e+00 val accuracy: 0.479000
hs 75 lr 8.000000e-04 reg 7.500000e-01 val accuracy: 0.475000
hs 75 lr 8.000000e-04 reg 1.000000e+00 val accuracy: 0.490000
hs 75 lr 8.000000e-04 reg 1.250000e+00 val accuracy: 0.485000
hs 75 lr 9.000000e-04 reg 7.500000e-01 val accuracy: 0.496000
```

```
hs 75 lr 9.000000e-04 reg 1.000000e+00 val accuracy: 0.494000
hs 75 lr 9.000000e-04 reg 1.250000e+00 val accuracy: 0.487000
hs 75 lr 1.000000e-03 reg 7.500000e-01 val accuracy: 0.471000
hs 75 lr 1.000000e-03 reg 1.000000e+00 val accuracy: 0.495000
hs 75 lr 1.000000e-03 reg 1.250000e+00 val accuracy: 0.495000
hs 75 lr 1.100000e-03 reg 7.500000e-01 val accuracy: 0.483000
hs 75 lr 1.100000e-03 reg 1.000000e+00 val accuracy: 0.492000
hs 75 lr 1.100000e-03 reg 1.250000e+00 val accuracy: 0.475000
hs 100 lr 7.000000e-04 reg 7.500000e-01 val accuracy: 0.476000
hs 100 lr 7.000000e-04 reg 1.000000e+00 val accuracy: 0.483000
hs 100 lr 7.000000e-04 reg 1.250000e+00 val accuracy: 0.477000
hs 100 lr 8.000000e-04 reg 7.500000e-01 val accuracy: 0.477000
hs 100 lr 8.000000e-04 reg 1.000000e+00 val accuracy: 0.480000
hs 100 lr 8.000000e-04 reg 1.250000e+00 val accuracy: 0.493000
hs 100 lr 9.000000e-04 reg 7.500000e-01 val accuracy: 0.504000
hs 100 lr 9.000000e-04 reg 1.000000e+00 val accuracy: 0.492000
hs 100 lr 9.000000e-04 reg 1.250000e+00 val accuracy: 0.472000
hs 100 lr 1.000000e-03 reg 7.500000e-01 val accuracy: 0.511000
hs 100 lr 1.000000e-03 reg 1.000000e+00 val accuracy: 0.490000
hs 100 lr 1.000000e-03 reg 1.250000e+00 val accuracy: 0.488000
hs 100 lr 1.100000e-03 reg 7.500000e-01 val accuracy: 0.510000
hs 100 lr 1.100000e-03 reg 1.000000e+00 val accuracy: 0.499000
hs 100 lr 1.100000e-03 reg 1.250000e+00 val accuracy: 0.480000
hs 125 lr 7.000000e-04 reg 7.500000e-01 val accuracy: 0.496000
hs 125 lr 7.000000e-04 reg 1.000000e+00 val accuracy: 0.482000
hs 125 lr 7.000000e-04 reg 1.250000e+00 val accuracy: 0.466000
hs 125 lr 8.000000e-04 reg 7.500000e-01 val accuracy: 0.460000
hs 125 lr 8.000000e-04 reg 1.000000e+00 val accuracy: 0.466000
hs 125 lr 8.000000e-04 reg 1.250000e+00 val accuracy: 0.479000
hs 125 lr 9.000000e-04 reg 7.500000e-01 val accuracy: 0.502000
hs 125 lr 9.000000e-04 reg 1.000000e+00 val accuracy: 0.499000
hs 125 lr 9.000000e-04 reg 1.250000e+00 val accuracy: 0.468000
hs 125 lr 1.000000e-03 reg 7.500000e-01 val accuracy: 0.489000
hs 125 lr 1.000000e-03 reg 1.000000e+00 val accuracy: 0.475000
hs 125 lr 1.000000e-03 reg 1.250000e+00 val accuracy: 0.509000
hs 125 lr 1.100000e-03 reg 7.500000e-01 val accuracy: 0.481000
hs 125 lr 1.100000e-03 reg 1.000000e+00 val accuracy: 0.477000
hs 125 lr 1.100000e-03 reg 1.250000e+00 val accuracy: 0.480000
best validation accuracy achieved during cross_validation: 0.511000
```

可以看到，在验证集上最好的识别准确率达到了0.511，这比我们前面说的几个分类器高出很多了，而且我们才仅仅使用了一个隐层，可见神经网络功能的强大。
我们将验证集准确率最高的模型保存在了`best_net`，以便我们接下来可以直接使用该模型进行预测。

我们也看下我们的神经网络学习到了什么，如下：

同样的第一层的权重，这次得到的特征就比上次我们得到的特征清晰很多了。

4 预测

我们直接可以使用上面保存好的 `best_net` 进行预测，代码如下：

```
test_acc=(best_net.predict(X_test)==y_test).mean()
print('test accuracy:' , test_acc)
```

最后得到的平均准确率如下：

```
test accuracy: 0.502
```

5 总结

这一节我们构建了一个两层的神经（全连接）网络，并使用该网络完成了对cifar10数据的分类工作。

神经网络和我们前面介绍的分类器不同的是，它的梯度更新方式是利用反向传播算法，反向传播算法是根据链式求导法则来计算的。